# Akciğer Kanser Tanılı Hastalarda Kanserli Doku Tespiti İçin Yapay Zeka Yöntemleri Kullanılarak Kanserli Bölgenin Konturlanması

Doç. Dr. H. Feza Carlak[1], İhsan Bahadır Emekli[1]

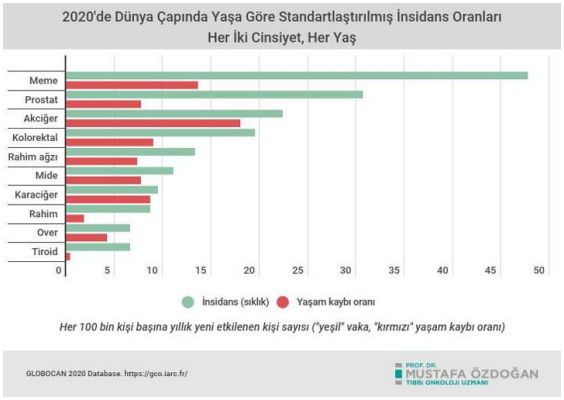
[1]Elektrik-Elektronik Mühendisliği Bölümü, Akdeniz Üniversitesi, Antalya, Türkiye

*Özet*— **Bu çalışma, akciğer kanseri tanısında PET/CT (Pozitron Emisyon Tomografisi/Bilgisayarlı Tomografi) görüntülerinin işlenmesi ve analizi için derin öğrenme modellerinin kullanımını araştırmaktadır. Akciğer kanseri, dünya genelinde en yaygın ve ölümcül kanser türlerinden biri olup, erken tanı ve doğru tedavi yöntemleri hastalığın prognozunu önemli ölçüde iyileştirebilir. PET/CT görüntüleme, kanserli dokuların tespiti ve değerlendirilmesinde yaygın olarak kullanılan bir yöntemdir. Ancak, bu görüntülerin manuel olarak analiz edilmesi zaman alıcı ve hataya açık bir süreçtir. Bu çalışmada, Akdeniz Üniversitesi Tıp Fakültesi Hastanesi Nükleer Tıp Anabilim Dalı'ndan alınan PET/CT görüntüleri kullanılarak, akciğer kanseri tanısında yüksek doğruluk ve hassasiyetle sınıflandırma ve segmentasyon yapabilen derin öğrenme modelleri geliştirilmiştir. İleri seviye derin öğrenme modelleri kullanılarak, kanserli ve sağlıklı dokuların otomatik olarak ayırt edilmesi ve kanserli bölgelerin hassas bir şekilde konturlanması hedeflenmiştir. Elde edilen sonuçlar, derin öğrenme modellerinin akciğer kanseri tanısında yüksek doğrulukla kullanılabileceğini göstermektedir. Bu çalışma, PET/CT görüntülerinin işlenmesi ve analizinde derin öğrenme tekniklerinin etkinliğini vurgulamakta ve tıbbi görüntü analizinde yeni ufuklar açmaktadır.**

**Anahtar Kelimeler: Akciğer kanseri, PET/CT görüntüleme, Derin öğrenme, Sınıflandırma, Segmentasyon**

## GİRİŞ

Kanser, dünya genelinde ciddi bir sağlık sorunu olarak karşımıza çıkmaktadır (1). Son yayımlanan global kanser istatistiklerine göre; 14,1 milyon yeni kanser vakası gelişmiş, 8,2 milyon kanserden kaynaklı ölüm olmuştur. Kanserdeki benzer seyrin devam etmesi durumunda 2030 yılında 22 milyon yeni vaka beklenmektedir (2). Şekil 1 de görüldüğü üzere akciğer kanseri hem görülme oranı hem de ölüm oranı açısında dünyadaki kanser vakaları içerisinde ilk sırada yer almaktadır. Erken teşhis ve doğru tedavi planlaması, hastaların yaşam süresini ve kalitesini önemli ölçüde artırabilir. Bu çalışmada, akciğer kanseri teşhisi ve tedavi planlaması sürecinde yapay zeka (AI) destekli görüntü işleme tekniklerinin kullanımını araştırdık. Amacımız, PET/CT görüntülerinden elde edilen verilerle kanserli dokuları otomatik olarak tespit edip konturlayarak, klinik tanı sürecine katkıda bulunmaktır.




*Şekil 1. Dünya Geneli Kanser Verileri*

Bu çalışma kapsamında, akciğer kanseri tanılı hastalara ait PET/CT görüntüleri kullanılarak iki aşamalı bir yaklaşım geliştirilmiştir. İlk aşamada, kanserli ve sağlıklı görüntüleri otomatik olarak ayırt edebilmek için InceptionV3 tabanlı bir sınıflandırma modeli eğitilmiştir. Sınıflandırma modelinde kanserli olarak tespit edilen kesitler, hassas bir konturlama için YOLOv8 tabanlı segmentasyon modeline gönderilmiştir. Bu süreçte, segmentasyon modeli kullanılarak kanserli bölgeler otomatik olarak konturlanmıştır.

Projenin ana hatları şu şekildedir:

1. **Veri Hazırlama**: PET/CT görüntülerinden elde edilen DICOM dosyaları, belirli ön işlemlerden geçirilerek PNG formatına dönüştürülmüştür. Bu aşamada, DICOM dosyaları temizlenmiş ve belirli bir sıra ile işlenmiştir.
2. **Model Eğitimi**: Sınıflandırma modeli, eğitim verileri ile eğitilmiştir. Model, kanserli ve sağlıklı görüntüleri başarıyla ayırt edebilmekte ve kanserli olarak tespit edilen kesitleri segmentasyon modeline yönlendirmektedir.
3. **Segmentasyon**: Segmentasyon modeli, sınıflandırma modeli tarafından belirlenen kanserli kesitleri hassas bir şekilde konturlamaktadır. Bu aşamada, segmentasyon sonuçları görselleştirilmiş ve gerçek maskelerle

karşılaştırılarak modelin doğruluğu değerlendirilmiştir.

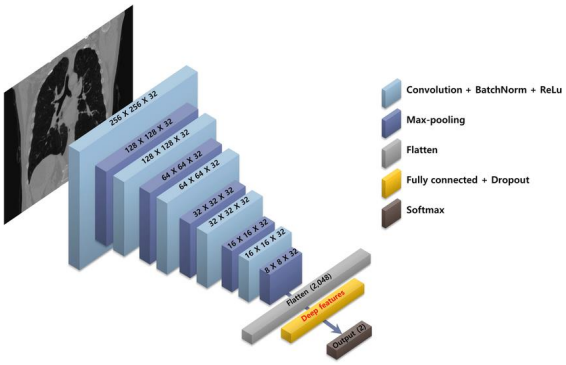
4. **Görüntüleme ve Değerlendirme**: Geliştirilen sistem, sonuçları bir GUI (Grafik Kullanıcı Arayüzü) aracılığıyla kullanıcıya sunmakta ve DICOM görüntülerini görselleştirmektedir. Ayrıca, sistemin performansı çeşitli metriklerle değerlendirilmiştir.

## LİTERATÜR ÇALIŞMASI

Makine öğrenmesi ve derin öğrenme teknikleri, tıbbi görüntüleme ve kanser tanısında son yıllarda önemli ilerlemeler kaydetmiştir. Akciğer kanseri tanısı ve segmentasyonu için geliştirilen modeller, doğru ve hızlı teşhis sağlayarak hasta yönetimini iyileştirme potansiyeline sahiptir. Bu bölümde, literatürde akciğer kanseri sınıflandırma ve segmentasyonuna yönelik yapılan çalışmalar incelenecektir.

### Akciğer Kanseri Sınıflandırma

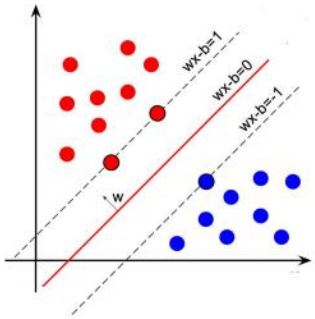
Akciğer kanseri sınıflandırma çalışmaları genellikle bilgisayarla görme ve derin öğrenme tekniklerine dayanmaktadır. Derin öğrenme modelleri, özellikle konvolüsyonel sinir ağları (CNN'ler)(şekil 2), tıbbi görüntülerin işlenmesinde yaygın olarak kullanılmaktadır.




*Şekil 2. CNN mimarisinin bir örneği*

Ardila ve arkadaşları (2019), düşük doz göğüs tomografisi (LDCT) görüntülerinde üç boyutlu derin öğrenme modeli kullanarak akciğer kanseri taraması gerçekleştirmişlerdir. Model, %94 doğruluk oranı ile yüksek performans sergilemiştir (3). Benzer şekilde, Nam ve arkadaşları (2019), derin öğrenme tabanlı otomatik bir tespit algoritması geliştirmiş ve göğüs radyografilerinde malign pulmoner nodüllerin tespitinde kullanmışlardır. Model, %92 doğruluk oranı ile yüksek başarı göstermiştir. Bu çalışma, derin öğrenme algoritmalarının kanser taramasında güvenilir bir yöntem olabileceğini ortaya koymaktadır (4).

Sevli ve Pazar (2020), akciğer kanseri verilerinin makine öğrenmesi yöntemleri ile sınıflandırılması üzerine çalışmışlardır. Çalışmada, destek vektör makineleri (şekil 3), rastgele orman ve lojistik regresyon gibi çeşitli makine öğrenmesi algoritmaları kullanılmış ve lojistik regresyon %97 doğruluk ile en yüksek performansı göstermiştir (5). Ayrıca, Zhang ve arkadaşları (2020) tarafından yapılan çalışmada, ResNet50 tabanlı bir model kullanılarak %93.1 doğruluk elde edilmiştir (6).

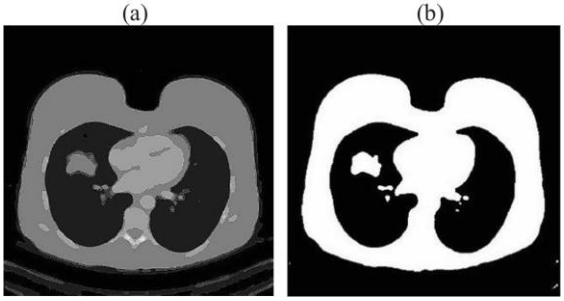



*Şekil 3 Destek Vektör Makinesi*

### Akciğer Kanseri Segmentasyonu

Akciğer kanseri segmentasyonu çalışmaları, kanserli bölgelerin doğru bir şekilde belirlenmesi ve konturlanması için geliştirilmiştir. Segmentasyon teknikleri, kanserli dokuların hacmini ve yayılımını doğru bir şekilde belirlemek için kullanılır.

Çakar ve arkadaşları (2017), National Cancer Institute (NCI) verilerini kullanarak akciğer tomografilerinde aday nodülleri tespit etmek için görüntü işleme teknikleri uygulamışlardır. Bu çalışmada, Otsu eşik belirleme (şekil 4) ve laplacian filtreleme yöntemleri kullanılarak aday nodüller tespit edilmiştir (7). Simões ve arkadaşları (2019) ise meme kanseri hedef hacmi otomatik şekillendirme yöntemlerinin geometrik ve dozimetrik değerlendirmesini yapmış ve otomatik konturlamanın manuel konturlama ile karşılaştırılabilir sonuçlar verdiğini göstermişlerdir (8).




*Şekil 4. (a) Filtrelenmiş Görüntü (b) Otsu Eşik Belirleme Metodu Uygulanmış Görüntü*

## MATERYAL VE YÖNTEM

### Veri Seti

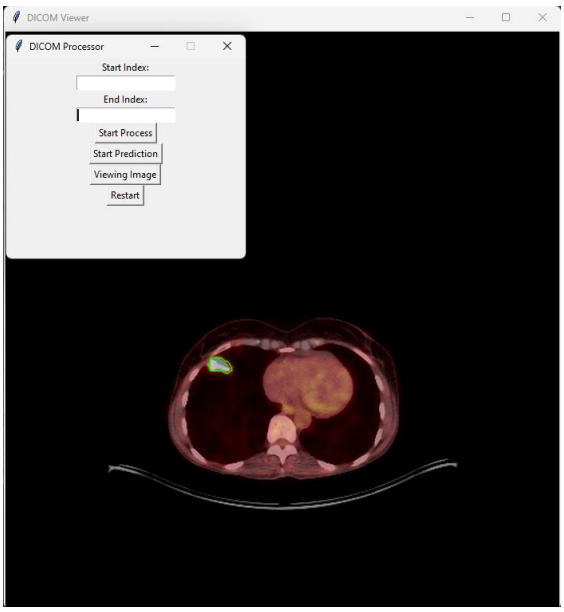
Bu çalışmada, Akdeniz Üniversitesi Tıp Fakültesi Hastanesi Nükleer Tıp Anabilim Dalı'ndan alınan akciğer kanseri tanılı hastalara ait PET/CT görüntüleri kullanılmıştır. Veri seti, çeşitli hastalardan elde edilen DICOM formatındaki görüntülerden oluşmaktadır. Veri seti 3000 kanserli ve 3000 sağlıklı kesit içermektedir.

Veri hazırlama süreci, verilerin sınıflandırma ve segmentasyon modellerinde kullanılabilecek hale getirilmesi için birkaç adımdan oluşmaktadır:

- İlk olarak, DICOM dosyaları PNG formatına dönüştürülmüş ve sıralanarak belirli bir aralıkta filtrelenmiştir. Dönüştürülen PNG dosyaları, model eğitimi ve değerlendirmesi için belirli bir dizine kaydedilmiştir.
- Veriler, sınıflandırma ve segmentasyon modellerinin eğitimi için uygun formatta hazırlanmıştır; eğitim, doğrulama ve test setlerine ayrılmış görüntüler normalleştirilmiş ve belirli bir boyuta ölçeklendirilmiştir.
- Geliştirilen sistemin veri hazırlama aşamasında, QuPath yazılımı kullanılarak kanserli bölgeler işaretlenmiş ve bu bölgelerin anotasyonları çıkartılmıştır. Anotasyonlar JSON formatında kaydedilerek, bu veriler üzerinde çeşitli ön işlemler yapılmış ve segmentasyon modelinin eğitiminde kullanılmıştır.
- Elde edilen anotasyonlardan maskeler oluşturulmuş ve belirli bir dizine kaydedilmiştir, bu maskeler segmentasyon modelinin eğitimi için kullanılmıştır.

### Görüntüleme ve Değerlendirme

Verilerin görselleştirilmesi ve değerlendirilmesi de modelin performansının belirlenmesi açısından büyük önem taşımaktadır. Bu çalışmada, oluşturulan maskeler ve gerçek maskeler görselleştirilmiş ve karşılaştırılmıştır. Görselleştirme işlemi için Matplotlib ve OpenCV kütüphaneleri kullanılmıştır. Tahmin edilen maskeler, gerçek maskelerle karşılaştırılarak modelin doğruluğu değerlendirilmiştir ve rastgele seçilen görüntüler ile bu görüntülere ait maskeler görselleştirilmiştir. Tahmin edilen maskeler ile gerçek maskeler arasındaki örtüşme oranı, IoU metriği kullanılarak hesaplanmıştır. Ayrıca, PNG formatına dönüştürülen dosyalar model eğitimi ve konturlama işlemlerinin ardından hiçbir veri kaybı olmadan tekrar DICOM formatına dönüştürülmüştür. Geliştirilen GUI (şekil 5), kullanıcıların DICOM görüntülerini görüntülemesini ve işlenmiş sonuçları incelemesini sağlamıştır. DICOM görüntüleyici, görüntülerin detaylı olarak incelenmesine olanak tanımıştır. Bu yöntemler, model performansının detaylı bir şekilde değerlendirilmesini sağlamıştır.




*Şekil 5 GUI*

### Kullanılan Makine Öğrenmesi Teknikleri

Bu çalışmada, akciğer kanseri görüntülerinin sınıflandırılması ve segmentasyonu için çeşitli makine öğrenmesi teknikleri kullanılmıştır. Ana bileşenler olarak InceptionV3 tabanlı bir sınıflandırma modeli ve YOLOv8 tabanlı bir segmentasyon modeli tercih edilmiştir.

Sınıflandırma modeli olarak kullanılan InceptionV3, Google tarafından geliştirilmiş bir derin öğrenme modelidir ve genellikle görüntü sınıflandırma görevlerinde yaygın olarak kullanılır. Bu çalışmada, InceptionV3 modeli akciğer kanseri görüntülerini kanserli ve sağlıklı olarak sınıflandırmak amacıyla kullanılmıştır. Model, farklı boyutlardaki özellikleri aynı anda öğrenebilmesi için farklı boyutlarda filtreler kullanarak aynı katmanda çoklu konvolüsyon işlemleri gerçekleştirir. ImageNet veri seti üzerinde önceden eğitilmiş ağırlıklarla başlatılan model, akciğer kanseri görüntüleriyle tekrar eğitilmiştir. Model, Adam optimizasyon algoritması kullanılarak derlenmiş ve eğitim süreci boyunca kategorik çapraz entropi kayıp fonksiyonu ve doğruluk metriği kullanılmıştır.

Segmentasyon modeli olarak YOLOv8 kullanılmıştır. YOLO (You Only Look Once) algoritması, gerçek zamanlı nesne tespiti ve segmentasyonu için kullanılan bir derin öğrenme modelidir ve YOLOv8, bu algoritmanın en yeni ve gelişmiş versiyonudur. YOLOv8, daha hızlı ve daha doğru nesne tespiti ve segmentasyonu yapabilen bir

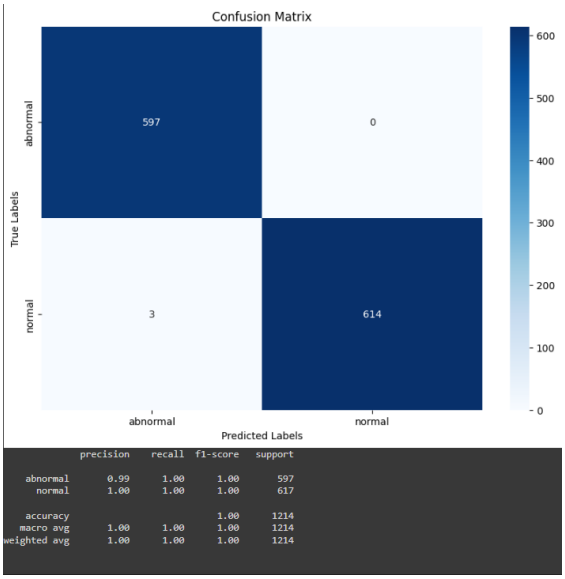
mimariye sahiptir. Model, aynı anda nesne konumlarını ve segmentasyon maskelerini tahmin edebilir. Sınıflandırma modelinden gelen kanserli kesitlerin hassas bir şekilde konturlanması amacıyla eğitilmiştir. Eğitim sürecinde SGD optimizasyon algoritması kullanılmıştır.

## DENEYSEL SONUÇLAR

Bu bölümde, sınıflandırma modelinin ve segmentasyon modelinin performansını değerlendiren deneysel sonuçlar sunulacak ve analiz edilecektir. Modellerin eğitim ve doğrulama setlerindeki performans metrikleri, görselleştirme sonuçları ve karşılaştırmalı analizler detaylandırılacaktır.

### Sınıflandırma Modeli Sonuçları

Modelin eğitim ve doğrulama setlerindeki doğruluk, hassasiyet, özgüllük ve F1 skoru gibi performans metrikleri Şekil 6'de sunulmuştur.




| | precision | recall | f1-score | support |
|---|---|---|---|---|
| abnormal | 0.99 | 1.00 | 1.00 | 597 |
| normal | 1.00 | 1.00 | 1.00 | 617 |
| accuracy | | | 1.00 | 1214 |
| macro avg | 1.00 | 1.00 | 1.00 | 1214 |
| weighted avg | 1.00 | 1.00 | 1.00 | 1214 |

*Şekil 6. Sınıflandırma modelinin performans metrikleri*

Confusion matrix ve performans metrikleri tablosu, modelin akciğer kanseri tanısındaki performansını değerlendirmektedir. Confusion matrix, modelin tahmin ettiği etiketler ile gerçek etiketler arasındaki ilişkiyi gösterir. Matriste yer alan dört ana bölge şu şekildedir:

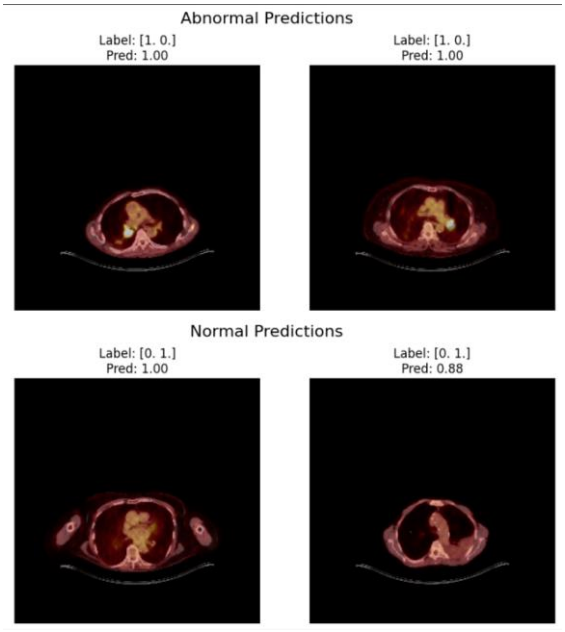
- True Positive (TP), modelin doğru bir şekilde "abnormal" olarak tahmin ettiği örnekleri (597)
- True Negative (TN), modelin doğru bir şekilde "normal" olarak tahmin ettiği örnekleri (614)
- False Positive (FP), modelin "abnormal" olarak tahmin ettiği fakat gerçekte "normal" olan örnekleri (0)
- False Negative (FN), modelin "normal" olarak tahmin ettiği fakat gerçekte "abnormal" olan örnekleri (3)

Performans metrikleri, modelin genel başarısını değerlendirmek için kullanılır. Aşağıda metriklerin tanımları ve bu model için yorumları bulunmaktadır:

- **Precision (Kesinlik)**: Modelin "abnormal" olarak tahmin ettiği örneklerin ne kadarının gerçekten "abnormal" olduğunu gösterir. Abnormal sınıfı için kesinlik 0.99, normal sınıfı için ise 1.00 olarak belirlenmiştir. Bu yüksek kesinlik değerleri, modelin doğru tahminlerde bulunduğunu ve yanlış pozitif oranının çok düşük olduğunu gösterir.
- **Recall (Duyarlılık)**: Gerçekten "abnormal" olan örneklerin ne kadarının doğru bir şekilde "abnormal" olarak tahmin edildiğini gösterir. Hem abnormal hem de normal sınıfları için duyarlılık 1.00 olarak hesaplanmıştır. Bu değerler, modelin yanlış negatif oranının neredeyse hiç olmadığını ve yüksek duyarlılık gösterdiğini ortaya koymaktadır.
- **F1-Score**: Precision ve recall'un harmonik ortalaması. Hem precision hem de recall'un dengeli olduğu durumlarda kullanışlıdır. Abnormal ve normal sınıfları için F1-skore değeri 1.00 olarak belirlenmiştir. Bu, modelin her iki sınıf için de mükemmel bir performans sergilediğini göstermektedir.
- **Accuracy (Doğruluk)**: Modelin doğru tahmin ettiği örneklerin toplam örnek sayısına oranıdır ve bu çalışmada doğruluk %100 olarak elde edilmiştir. Bu sonuç, modelin tüm örnekleri doğru bir şekilde sınıflandırdığını ve genel performansının mükemmel olduğunu göstermektedir.
- **Support**: Her bir sınıfın gerçek örnek sayısını gösteren destek (support) metriği, abnormal sınıfı için 597 ve normal sınıfı için 617 olarak kaydedilmiştir. Bu veriler, modelin yeterli miktarda veri ile eğitildiğini ve test edildiğini göstermektedir.

InceptionV3 modelinin confusion matrix ve performans metrikleri, modelin akciğer kanseri tanısında oldukça yüksek bir performans gösterdiğini ortaya koymaktadır. Model, %100 doğruluk oranına ulaşarak neredeyse tüm "abnormal" ve "normal" örnekleri doğru bir şekilde sınıflandırmıştır (Şekil 7). Özellikle, precision ve recall değerlerinin her ikisi de 1.00 veya yakınında olup, modelin hem doğru pozitif hem de doğru negatif oranlarını yüksek tuttuğunu göstermektedir. Yalnızca üç adet "normal" örneğin "abnormal"

olarak yanlış sınıflandırıldığı görülmektedir, bu da modelin performansını önemli ölçüde etkilememektedir.

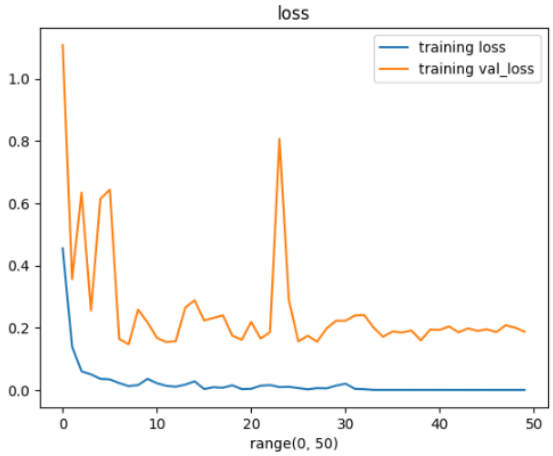



*Şekil 7 Sınıflandırma Modeli Tahminleri*

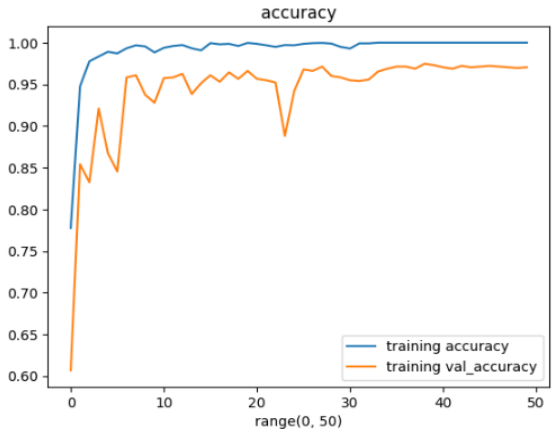
Bu sonuçlar, literatürde akciğer kanseri görüntü sınıflandırması için yapılan diğer çalışmalarla karşılaştırıldığında rekabetçi ve üstün performans sergilemektedir. Örneğin, Zhang ve ark. (2020) tarafından yapılan çalışmada, ResNet50 tabanlı bir model kullanılarak %93.1 doğruluk elde edilmiştir (6) . Bu çalışmada kullanılan InceptionV3 modeli, %100 doğruluk değeri ile bu çalışmanın üzerinde bir performans sergilemiştir. Ayrıca, Hassani ve ark. (2019) tarafından yapılan çalışmada, VGG16 tabanlı bir modelle %91.5 doğruluk elde edilmiştir (9) . Geliştirilen model, bu çalışmanın da üzerinde bir performans göstererek akciğer kanseri tanısında daha güvenilir bir sınıflandırma sağlamaktadır.

Eğitim ve Doğrulama Kayıp ve Doğruluk Değerleri:

Modelin eğitim ve doğrulama sürecindeki kayıp ve doğruluk değerleri Şekil 8 ve Şekil 9'de gösterilmiştir. Eğitim sürecinde kayıp fonksiyonunun azaldığı ve doğruluk değerlerinin arttığı gözlemlenmiştir. Bu, modelin öğrenme sürecinde başarılı olduğunu ve eğitim verileri üzerinde iyi bir performans sergilediğini göstermektedir.




*Şekil 8. Eğitim ve doğrulama kaybı grafiği*



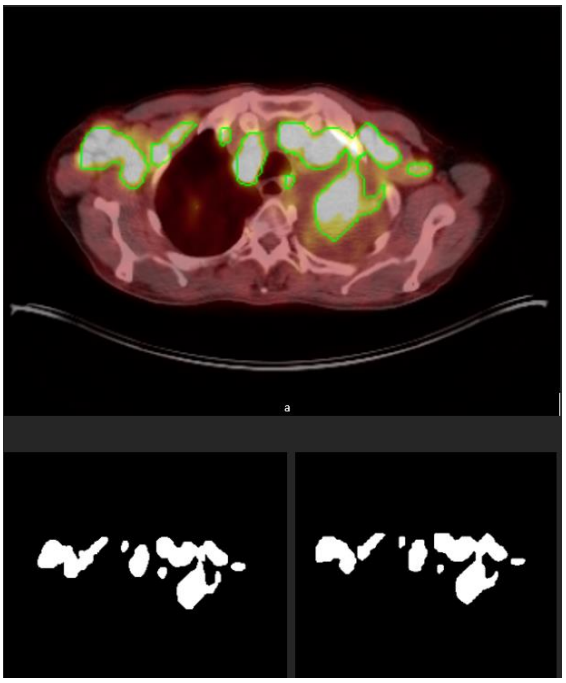

*Şekil 9. Eğitim ve doğrulama doğruluk grafiği*

Segmentasyon Modeli Sonuçları

Bu bölümde segmentasyon modelinin performans metrikleri değerlendirilecek ve yorumlanacaktır.

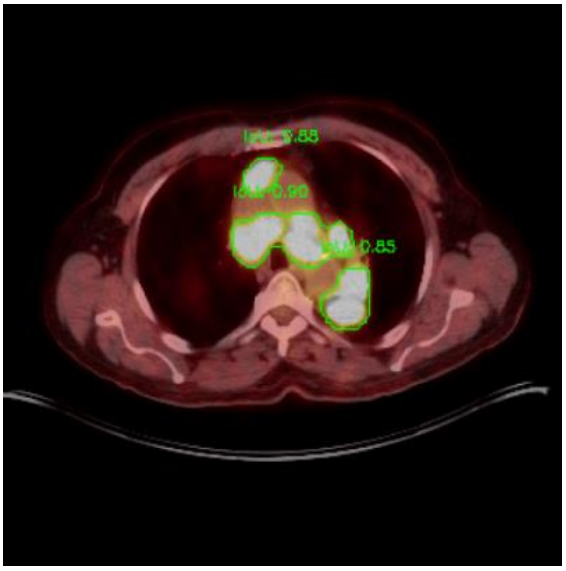
Tahmin Edilen ve Gerçek Maskelerin Görselleştirilmesi:

Rastgele seçilen birkaç görüntü için tahmin edilen maskeler ve gerçek maskeler görselleştirilmiş ve karşılaştırılmıştır. Şekide (a) tahmin edilen konturlar, (b) gerçek maskeler ve (c) tahmin edilen maskelerdir. Tahmin edilen maskelerin gerçek maskelerle ne kadar iyi örtüştüğü görülmektedir.



*(b)* *(c)*

Ayrıca tahmin edilen maskeler için IoU değeri hesaplanmış ve modelin segmentasyon performansı değerlendirilmiştir.



*Şekil 11. Konturların IoU değerleri*

Performans Metrikleri:

- **Precision (Kesinlik)**: Kesinlik, modelin belirlediği segmentasyonların ne kadarının doğru olduğunu gösterir. Modelin benign (iyi huylu) örnekler için kesinliği 0.888, malign (kötü huylu) örnekler için ise 0.824 olarak ölçülmüştür. Bu değerler, modelin özellikle benign örneklerde yüksek doğrulukla çalıştığını göstermektedir. Malign örnekler için kesinlik biraz daha düşük olsa da, hala kabul edilebilir düzeydedir.
- **Recall (Duyarlılık)**: Duyarlılık, modelin gerçekten doğru olan segmentasyonları ne kadar iyi tespit ettiğini gösterir. Benign örnekler için duyarlılık 0.817, malign örnekler için ise 0.767 olarak ölçülmüştür. Bu, modelin özellikle benign örneklerde yüksek bir tespit oranına sahip olduğunu, ancak malign örneklerde tespit oranının biraz daha düşük olduğunu göstermektedir.
- **mAP50**: IoU eşik değeri 0.50 olan segmentasyonlar için ortalama doğruluk değeridir. Benign örnekler için mAP50 değeri 0.897, malign örnekler için ise 0.828 olarak ölçülmüştür. Bu, modelin segmentasyon doğruluğunun yüksek olduğunu göstermektedir.

## TARTIŞMA VE SONUÇ

Bu bölümde, çalışmanın bulguları ve elde edilen sonuçlar tartışılacak, çalışmanın güçlü ve zayıf yönleri ele alınacak ve gelecekte yapılabilecek çalışmalar için önerilerde bulunulacaktır.

### Bulguların Tartışılması

Bu çalışmada, akciğer kanseri tanısı ve tedavi planlamasında kullanılmak üzere geliştirilen InceptionV3 tabanlı sınıflandırma modeli ve YOLOv8 tabanlı segmentasyon modelinin performansı değerlendirilmiştir. Elde edilen sonuçlar, geliştirilen modellerin akciğer kanseri görüntülerini başarılı bir şekilde sınıflandırabildiğini ve kanserli bölgeleri hassas bir şekilde konturlayabildiğini göstermektedir.

- **Sınıflandırma Performansı**: InceptionV3 tabanlı sınıflandırma modeli, yüksek doğruluk, hassasiyet ve özgüllük değerleri elde etmiştir. Bu, modelin kanserli ve sağlıklı görüntüleri etkili bir şekilde ayırt edebildiğini göstermektedir. Ancak, yanlış pozitif ve yanlış negatif oranları da dikkate alınmalı ve bu oranların azaltılması için modelin daha fazla veri ile eğitilmesi veya daha karmaşık modellerin kullanılması düşünülebilir.
- **Segmentasyon Performansı**: YOLOv8 tabanlı segmentasyon modeli, kanserli bölgeleri doğru bir şekilde konturlayabilmiştir. Bu, modelin klinik uygulamalarda kullanılabilirliğini artırmaktadır. Ancak, bazı görüntülerde düşük IoU değerleri elde edilmiştir ve bu durum, modelin belirli durumlarda daha az başarılı olduğunu göstermektedir. Bu sorunun çözülmesi için modelin daha fazla veri ile

eğitilmesi ve segmentasyon algoritmalarının iyileştirilmesi gerekmektedir.

Güçlü ve Zayıf Yönler

Güçlü Yönler:

- **Yüksek Doğruluk ve Hassasiyet**: Geliştirilen modeller, yüksek doğruluk ve hassasiyet değerleri ile akciğer kanseri tanısı ve tedavisinde kullanılabilir.
- **Kapsamlı Veri Hazırlama**: DICOM dosyalarının temizlenmesi, PNG formatına dönüştürülmesi ve anotasyonların çıkartılması gibi detaylı veri hazırlama adımları, model performansını olumlu yönde etkilemiştir.
- **Hasta Verileri:** DICOM dosyalarını PNG formatına dönüştürme işleminde DICOM dosyalarındaki hiçbir hasta verisinin zarar görmemesi sağlanmıştır.

Zayıf Yönler:

- **Sınırlı Veri Seti**: Kullanılan veri seti, belirli bir hastaneden alınmış sınırlı sayıda görüntüden oluşmaktadır. Daha geniş ve çeşitli veri setleri ile model performansı artırılabilir.
- **Yanlış Pozitif ve Negatif Oranları**: Sınıflandırma modelinde yanlış pozitif ve negatif oranları mevcut olup, bu oranların azaltılması gerekmektedir.
- **Segmentasyon Hataları**: Bazı görüntülerde segmentasyon hataları ve düşük IoU değerleri elde edilmiştir. Bu durum, modelin belirli durumlarda daha az başarılı olduğunu göstermektedir.

Gelecek Çalışmalar İçin Öneriler

- **Daha Geniş ve Çeşitli Veri Setleri**: Model performansını artırmak için daha geniş ve çeşitli veri setleri kullanılmalıdır. Farklı hastanelerden ve farklı hasta gruplarından elde edilen veriler, modelin genelleme yeteneğini artıracaktır.
- **Model İyileştirmeleri**: Yanlış pozitif ve negatif oranlarını azaltmak için daha karmaşık modeller ve ileri düzey veri artırma teknikleri kullanılabilir. Ayrıca, segmentasyon modelinin performansını artırmak için yeni algoritmalar ve optimizasyon teknikleri araştırılabilir.
- **Klinik Uygulamalar**: Geliştirilen modellerin klinik uygulamalarda kullanılması için kapsamlı klinik değerlendirmeler yapılmalıdır. Modelin gerçek dünya verileri ile test edilmesi ve klinik geri bildirimlerle iyileştirilmesi gerekmektedir.
- **Entegre Sistemler**: Sınıflandırma ve segmentasyon modellerinin entegre edildiği bir sistem geliştirilerek, klinik tanı süreçlerinin daha verimli ve etkili hale getirilmesi sağlanabilir. Bu sistem, doktorların hızlı ve doğru kararlar almasına yardımcı olabilir.

Sonuç

Bu çalışma, yapay zeka destekli sınıflandırma ve segmentasyon tekniklerinin akciğer kanseri tanısı ve tedavi planlamasında etkin bir şekilde kullanılabileceğini göstermektedir. Bu bulgular, yapay zeka teknolojilerinin sağlık alanındaki potansiyelini vurgulamakta ve gelecekteki çalışmalar için önemli bir temel oluşturmaktadır.

Gelecekte, daha geniş veri setleri ve ileri düzey tekniklerle bu sistemlerin performansının daha da artırılması ve klinik uygulamalarda yaygın olarak kullanılması hedeflenmektedir.

## KAYNAKLAR


[1] Huang, Y., et al. (2019). "Performance of deep learning models for screening of pulmonary nodules". *The Lancet Digital Health*.

[2] Çermik, T. F. (2020). "PET-CT'nin diagnostik onkolojideki yeri". *Sağlık Bilimleri Üniversitesi Tıp Fakültesi Nükleer Tıp Anabilim Dalı*.

[3] Ardila, D., et al. (2019). "End-to-end lung cancer screening with three-dimensional deep learning on low-dose chest computed tomography". *Nature Medicine*.

[4] Nam, J. G., et al. (2019). "Development and Validation of Deep Learning-based Automatic Detection Algorithm for Malignant Pulmonary Nodules on Chest Radiographs". *Radiology*.

[5] Sevli, O., & Pazar, M. E. (2020). "Classification of Lung Cancer Data with Different Machine Learning Techniques". *Euro Asia 7th International Congress on Applied Sciences*.

[6] Zhang, Y., et al. (2020). "Deep Learning Model for Lung Cancer Diagnosis". *Journal of Medical Imaging*.

[7] Çakar, E., Türker, A. Y., Güleryüz, E., & Karaca, A. (2017). "Detection of Candidate Nodules in Lung Tomography by Image Processing Techniques". *IEEE BIYOMUT*.

[8] Simões, R., Wortel, G., Wiersma, T. G., Janssen, T. M., van der Heide, U. A., & Remeijer, P. (2019). "Geometrical and dosimetric evaluation of breast target volume automatic contouring". *Physics and Imaging in Radiation Oncology*.

[9] Hassani, S., et al. (2019). "VGG16-Based Model for Lung Cancer Classification". *Computers in Biology and Medicine*.